法律声明

- 本课件包括：演示文稿，示例，代码，题库，视频和声音等，小象学院拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意，我们将保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

分布式爬虫

大纲

- 倒排索引
- 文本匹配及排序
- Elastic Search

倒排索引

核心-倒排表

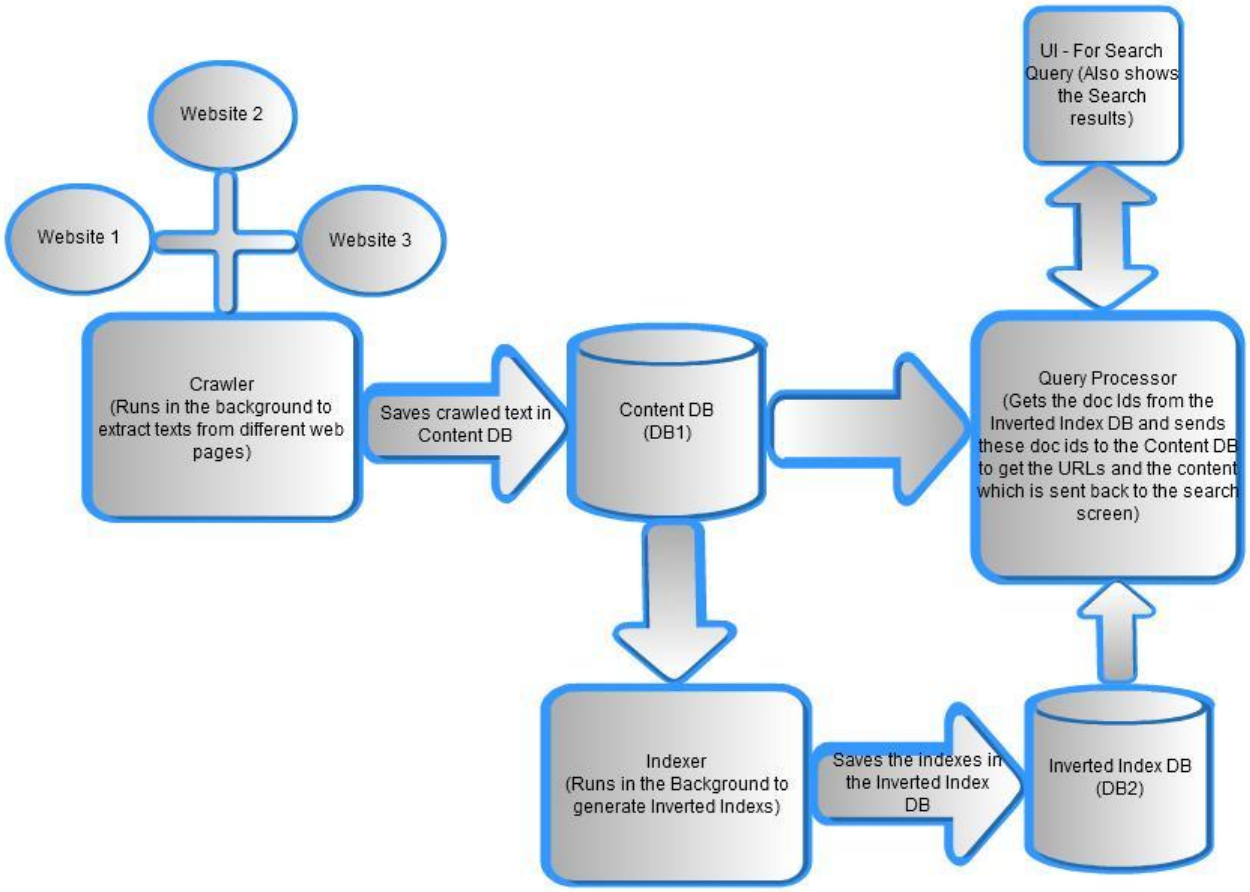
Website 2
Website 1
Website 3
Crawler
(Runs in the background to extract texts from different web pages)
Saves crawled text in Content DB
Content DB
(DB1)
UI - For Search Query (Also shows the Search results)
Query Processor
(Gets the doc Ids from the Inverted Index DB and sends these doc ids to the Content DB to get the URLs and the content which is sent back to the search screen)
Indexer
(Runs in the Background to generate Inverted Indexs)
Saves the indexes in the Inverted Index DB
Inverted Index DB
(DB2)

处理过程

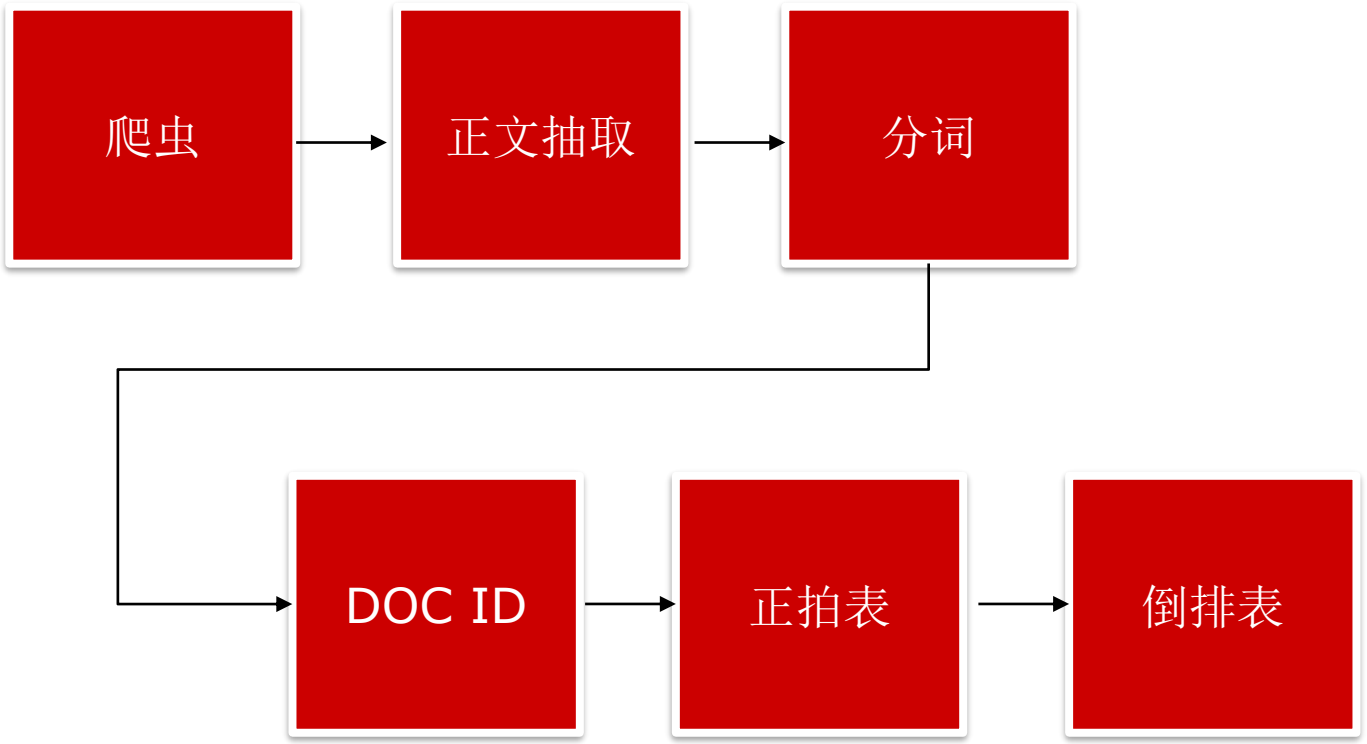

正排索引

- LocalId：文档的局部编号
- WordId：文档分词后的编号
- nHits：某个索引词出现的次数
- HitList 变长字段：某个索引词在文档出现的位置

倒排索引

- 词典：不同索引词组成的索引表

WordID	nDocs	Offset
dog	208	120
cat	13	175
…	…	…

DocId	NHits	HitList
Doc1	8	12,35
Doc2	13	175
Doc1		
Doc2		
Doc3		
Doc4		
…	…	…

- 记录表：每个索引词出现过的文档集合以及命中位置

查询系统

Boolean 模型

单纯地查询每个检索词，最后把检索词的结果取交集

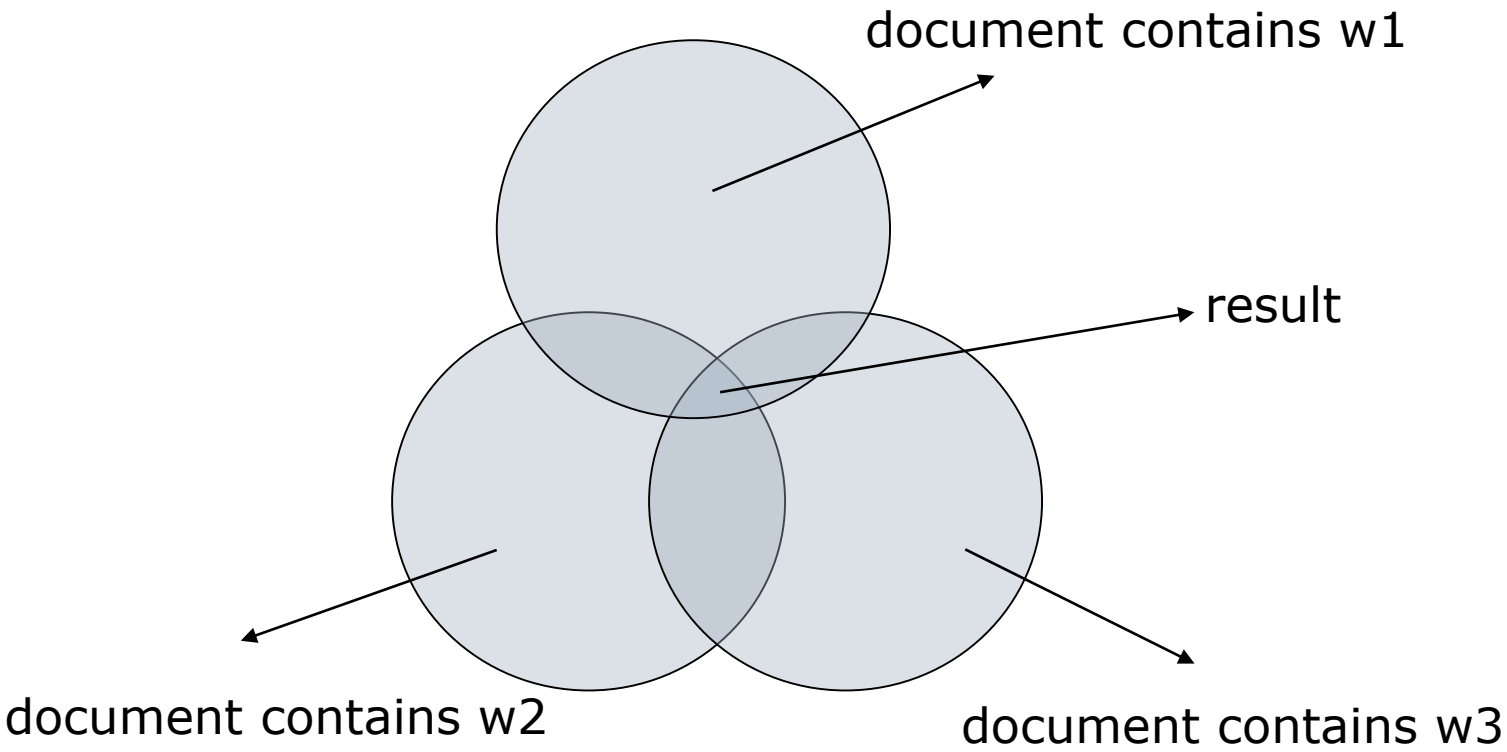

词与词的关联

在提取特征词的时候，我们可以用 TfIdf 来找出特征词，同时TfIdf 也可以用来表述一个词 w_i 对于一篇文章 d_j 的重要性 $w_{i,j}$

Boolean的检索方式，词与词之间被看成是独立的，而实际上，搜索词之间的组合，是具备一定关联，关联定义

$$C_{u,v} = \sum_{d_j} w_u \times w_v$$

标准化网页长度

一般来说，一篇网页的文本越长，它被随机搜索词命中的几率也就越大。因此我们需要考虑把网页的长度进行标准化，一般来说，网页文本长度有以下的方式来表达：

- Size in Bytes：网页文本流的长度
- Size in Words：网页字词数量

- 向量的模：$|d_i| = \sqrt[2]{\sum_{i=0}^{n} w_{i,j}^2}$ 其中 $w_{i,j}$ 是每个词在文档 j 的权重

向量模型

假设一个搜索系统，全部的搜索词数量为 t，那么搜索词与一篇文档，可以表达为

$$d_j = (w_{1,j}, w_{2,j}, \ldots, w_{t,j})$$

$$q = (w_{1,q}, w_{2,q}, \ldots, w_{t,q})$$

相似度可以表示为：

$$sim(d_j, q) = \frac{d_j \cdot q}{\|d_j\| \times \|q\|}$$

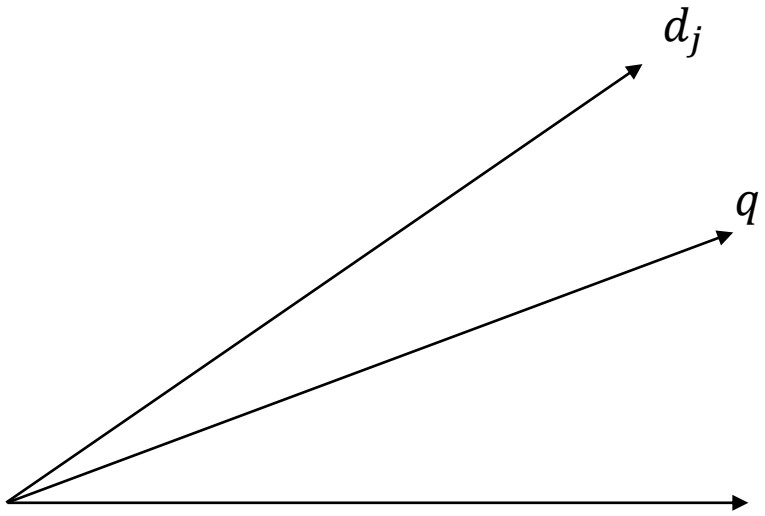

概率模型

假设对于一个搜索，相关的文档的全集为 R，不相关的文档的集合为R'，于是我们可以得到一篇文档与查询总的相关度为：

$$sim(d_j, q) = \frac{P(R|d_j, q)}{P(R'|d_j, q)}$$

我们可以得到这样的一个相关性：

$$sim(d_j, q) \sim \sum_{k_i \in q \cap k_i \in d_j} \log\left(\frac{p_{iR}}{1 - p_{iR}}\right) + \log\left(\frac{1 - q_{iR}}{q_{iR}}\right)$$

其中 $p_{iR} = P(k_i|R, q)$, $q_{iR} = P(k_i|R', q)$

从集合R中一个随机选择一个文档，第 i 个索引词k_i 出现和不出现在这个文档的概率，就是 p_{iR} 及 q_{iR}

概率模型

$$sim(d_j, q) \sim \sum_{k_i \in q \cap k_i \in d_j} \log\left(\frac{p_{iR}}{1-p_{iR}}\right) + \log\left(\frac{1-q_{iR}}{q_{iR}}\right)$$

集合R在最开始不知道的，我们可以这样来推导

	相关搜索	不相关搜索	全部
文档包含k_i	r_i	$n_i - r_i$	n_i
文档不包含k_i	$R - r_i$	$N - n_i - (R - r_i)$	$N - n_i$
全部文档	R	$N - R$	N

把上面的关系带入，最后我们可以推导出：

$$sim(d_j, q) \sim \sum_{k_i \in q \cap k_i \in d_j} \log\left(\frac{(r_i + 0.5)(N - n_i - R + r_i + 0.5)}{(R - r_i + 0.5)(n_i - r_i + 0.5)}\right)$$

概率模型

我们并不知道R 和 r_i，因此假设 $R = r_i = 0$，得到第一轮的结果：

$$sim(d_j, q) \sim \sum_{k_i \in q \cap k_i \in d_j} \log\left(\frac{N - n_i + 0.5}{n_i + 0.5}\right)$$

我们可以把计算的结果，从文档里取出来一个子序列，然后估算得到 R，r_i，重新带入到前面的公式，反复地进行计算

几种模型的简单比较

- Boolean Model：比较简单粗暴，结合词的权重能得到不错的结果；如果一篇文章漏掉了一个搜索词就不能被检索到
- Vector Model：容错性能较好，对于比较多的搜索词，查询结果比较好；反过来对于很长的文章，精度不高，对于1、2个词的搜索，效果不好
- Probability Model：理论上结果是最优的，文档按照相关度降序排列，但是实践中，初始值的估算会带来比较大的误差，并没有利用词频以及标准化文档长度

模糊匹配

对于穆罕默德、默罕默德、穆罕穆德，正确写法应该是 穆罕默德，如何确保不管搜索哪个词，都能得到“穆罕穆德”的相关结果？

准备过程

先把所有检索词的拼音记录下来，并保存2个拼音的列表，一个是拼音首字母组合表，第二个是拼音的全拼列表，同样形成拼音->词语的倒排表

词	拼音	首字母
穆罕穆德	muhanmude	mhmd
孔子	kongzi	kz
爱因斯坦	aiyinsitan	ayst

首字母	词
ays	安阳市
ayst	爱因斯坦

拼音	词
muhanmode	穆罕默德
mohanmodi	穆罕默迪

搜索过程

1. 用户开始输入的时候，把完整词、拼音首字母与完整拼音都提取出来，分别进入到索引系统查询
2. 查询的结果，根据匹配完整度和候选词热度综合来排序，一般如果有完整匹配，优先完整匹配的词，然后依次是拼音匹配、热度从高到底
3. 精准匹配失败，意味着搜索词不存在，开始启用纠错功能，纠错的时候，假设搜索词的长度是正确的，只是出现了错别字，因此分别过滤掉一个字进行搜索

日志系统

- 用户信息（ID）
- 查询信息：查询字符串、时间、终端类型、前面的若干个查询词
- 点击信息：点击的URL、时间、点击URL在结果集中的位置
- 结果展现：所搜索结果、广告结果、广告点击

作用

- 用户偏好分析及用户画像
- 热点词排序
- 输入Suggestion及纠错
- 查询结果缓存一句：10%的查询词占据总搜索量的50%
- 类别识别：Harry Potter Movie/Book 统计来对 Harry Potter 自动分类
- 搜索结果优化：根据用户点击来调整网站排名，一般排名靠前的网页本身有比较高的点击率，因此统计分析的时候要把结果进行修正
- 查询词相关性分析：单位时间内连续几个查询词和点击具备相关性

Elastic Search

简介

- 基于 Apache Luence，Java 开发的搜索引擎
- 开源项目
- 支持分布式部署
- 基于 RESTful 接口的调用方式
- 开源网址：https://github.com/elastic/elasticsearch
- 支持集群，支持分片和复制

https://www.elastic.co/

基本术语

- 集群：一个集群就是由一个或多个节点组织在一起，它们共同持有你整个的数据，并一起提供索引和搜索功能
- 节点：一个节点是你集群中的一个服务器，作为集群的一部分，它存储你的数据，参与集群的索引和搜索功能
- 索引：一个索引就是一个拥有几分相似特征的文档的集合
- 类型：在一个索引中，你可以定义一种或多种类型。一个类型是你的索引的一个逻辑上的分类/分区
- 文档：一个文档是一个可被索引的基础信息单元，比如一篇网页可以作为一个文档被加入到系统中

https://www.elastic.co/

安装与启动

下载：

https://artifacts.elastic.co/downloads/elasticsearch/elasticsearch-5.3.0.zip

启动：

Run bin/elasticsearch (or bin\elasticsearch.bat on Windows)

访问：

http://localhost:9200/

https://www.elastic.co/

安装 IK 分词器

下载：

open source: https://github.com/medcl/elasticsearch-analysis-ik

jar: https://github.com/medcl/elasticsearch-analysis-ik/releases/download/v5.3.0/elasticsearch-analysis-ik-5.3.0.zip

copy and unzip target/releases/elasticsearch-analysis-ik-{version}.zip to your-es-root/plugins/ik

重启 elasticsearch

https://www.elastic.co/

基本信息查看

Elastic Search 完全是基于 RESTful 接口来操作的，支持操作方法包括 PUT POST GET DELETE 等

查看基本信息

curl 'localhost:9200/_cat/health?v'

epoch timestamp cluster status node.total node.data shards pri relo init unassign
1394735289 14:28:09 elasticsearch green 1 1 0 0 0 0 0

https://www.elastic.co/

创建索引

curl -XPUT 'localhost:9200/htmlcontent?pretty'

上面的命令创建了一个叫做 htmlcontent的索引

pretty 是使得打印JSON返回的时候进行格式化

curl 'localhost:9200/_cat/indices?v'

这个命令用来查看系统已经存在的索引

Python urllib2 的 PUT

```
opener = urllib2.build_opener(urllib2.HTTPHandler)
req = urllib2.Request(base_url + '/html?pretty', data=json.dumps(data))
req.get_method= lambda: 'PUT'
print opener.open(req)
```

需要使用 build_opener 来设定 PUT 方法（后面的 DELETE 也一样）

创建 Mapping

为了让搜索引擎知道各个Field的类型，例如 time，文本，整数，我们可以对 index 创建mapping。创建mapping 的时候同时指定 analyzer 也就是中文分词器

Mapping 支持的数据类型：

- String: string
- Whole number: byte, short, integer, long
- Floating-point: float, double
- Boolean: boolean
- Date: date

创建 Mapping

```
data = {
        "mappings":{
                "travel":{
                        "properties":{
                                "title":{
                                        "type":"string",
                                        "analyzer": "ik_smart"
                                },
                                "content": {
                                        "type":"string",
                                        "analyzer": "ik_smart"
                                }
                        }
                }
        }
}
```

添加文档

```
PUT htmlcontent/travel/1
{
        "url" : "http://www.mafengwo.cn/i/1982738.html",
        "post_date" : "2009-11-15T14:12:12",
        ”title" : ”浪漫天堂-塞舌尔"
        "content" : ”抽取的网页正文"
}
```

这个命令把文档存到了 htmlcontent 索引下，type 为travel 的类型下，文档编号为1

添加文档后的信息


```
{
        "_shards" : {
                "total" : 2,
                "failed" : 0,
                "successful" : 2
        },
        "_index" : "htmlcontent",
        "_type" : "travel",
        "_id" : "6a8ca01c-7896-48e9-81cc-9f70661fcb32",
        "_version" : 1,
        "created" : true,
        "result": "created"
}
```

直接获取文档

GET htmlcontent/travel/0

直接使用GET命令，后面指明文档ID，可以直接获取一篇文档

HEAD htmlcontent/travel/0

使用HEAD命令，类似用法，可以检查一篇文档是否存在

查询后删除

POST htmlcontent/_delete_by_query

```
curl -XPOST 'localhost:9200/twitter/_delete_by_query?pretty' -H 'Content-Type: application/json' -d’{  "query": {     "match": {      "message": "some message" } }}'
```

直接基于查询 _delete_by_query 命令，在BODY里，指明 query 条件来删除

https://www.elastic.co/guide/en/elasticsearch/reference/current/docs-delete-by-query.html

更新文档

POST test/type1/1/_update

```
{
    "script" : {
        "inline": "ctx._source.tags.add(params.tag)",
        "lang": "painless",
        "params" :
        {
            "tag" : "blue"
        }
    }
}
```

curl 命令直接更新一个文档

```
curl -XPOST 'localhost:9200/htmlcontent/travel/1/_update?pretty' -H 'Content-Type: application/json' -d'{    "doc" : {        "title" : "new title"    }}'
```

Update by Query

POST twitter/_update_by_query

```
{
    "script": {
            "inline": "ctx._source.likes++",
            "lang": "painless"
        },
    "query": {
        "term": {
            "user": "kimchy"
        }
    }
}
```

直接利用 update 和 script 命令组合，来查询一个文档并修改

查询文档

查询可以直接通过 URI 来进行，即

GET /html/_search?q=content:塞舌尔

也可以通过 QUERY DSL 来查询，支持三种级别：基于Boolean 的 Match、Term 和 Range。Match 是基于针对的查询，Term 是针对单个词的查询，range 是针对数学上的 大于、小于（lt、gt、gte）等

查询文档 – Term

```
data = {
        "query": {
                "term":{"content":"塞舌尔"}
        },
        "from": 0,
        "size": 10,
        "sort":{ "_score": "desc"}
}

req = urllib2.Request(base_url + '/html/_search?pretty', data=json.dumps(data))
response = urllib2.urlopen(req)
print response.read()
```

查询文档 - Match

```
data = {
        "query": {
                ”match”:{“content”:”塞舌尔 自驾"}
        },
        "from": 0,
        "size": 10,
        "sort":{ "_score": "desc"}
}

req = urllib2.Request(base_url + '/html/_search?pretty', data=json.dumps(data))
response = urllib2.urlopen(req)
print response.read()
```

查询文档 – Multi Match

```
match_data = {
        "query": {
                "multi_match":{
                        "query":"塞舌尔 自驾",
                        "fields": [ "title", "content" ]
                }
        },
        "from": 0,
        "size": 10,
        "sort":{ "_score": "desc"}
}
```

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-multi-match-query.html

疑问

- 问题答疑： http://www.xxwenda.com/
  - 可邀请老师或者其他人回答问题

联系我们

小象学院：互联网新技术在线教育领航者

- 微信公众号：大数据分析挖掘
- 新浪微博：ChinaHadoop